

불확실성(Uncertainty)

- 현실세계: 복잡, 예측이 어렵다. 비논리적, 상호 모순적인 상황들로 얽혀 있다. → 과학, 공학: 단순화, 규칙성 부여
- 시스템 내외부에 존재하는 불확실성에 대처할 필요
- 단순화된 모델, 정형화된 기법의 한계

현실과 과학

불확실성 해결 기법

불확실하고 상호 모순적인 정보로부터 지식베이스의 일관성 유지
불확실성을 정량화 하는 확률적 기법

논리 추론 (만약), 비모순성 (부적)으로 가정한 명제와 새로운 명제 간들간의, 지체없이(또한) 상호 모순되는 것 없음 즉 공명
→ 일관성을 유지해야함...

기정사실을 하연으로 잡는다
→ 딱 함/거짓 불가
→ 확률 도입하자

↓
여전히 제한적
인간의 불확실성에 대한 대처능력과는 비교 불가능

(인간 불확실성에 대해 대처할 수 있는 능력)

CMU's 무인 주행 자동차, NAVLAB

컴퓨터 외에 카메라, 레이더, 레이저 거리탐지기 같은 센서들,
다수의 통신용 안테나를 갖고 있지만, 주행 중 돌발상황 대처 부족

다중 센서로 돌발상황
예측할 수 있음에도 불구하고 돌발상황

4. 불확실성



불확실성 요인

데이터의 불확실성

센서 장치로부터 얻어지는 데이터는 불완전
→ 감각 X 한계가 있을수밖에...
은닉 포함할수밖에...
여러 요인에 의한 오차가 포함된 데이터

지식의 불확실성

지식은 모호하고 휴리스틱한 절차에 의해 입수
특정된 거 보고도 여러가지 해석이 가능하고, 지식은 알려지지 않은

동일한 전문 영역의 지식도 불일치 가능

표현 및 저장시의 문제점
컴퓨터로 처리 인은 지각 → 사람이 알지 못하는 것을 표현, 이해...

정보의 불완전성

불완전하고 부분적인 정보로부터 판단해야 할 경우
비록은 문제

무인주행 자동차: 경로상의 모든 상황에 대한 방대한 정보 입수불가

확률적 불규칙성

예측 불가능한 요인에 의해 발생하는 불규칙성

(예를 들어 날씨 예측은 날씨 예측이 아니라 날씨 예측)

비단조 추론(Nonmonotonic Reasoning)

기존 논리체계

→ 필요한 정보만 있을, 모순은 없음 (Consistency),

문제해결에 필요한 모든 정보 존재 또는 1차 논리로 유도(완전성: Completeness)

정보 상호간에 모순이 없다(일관성: Consistency)

참으로 알려진 정보의 숫자는 줄지 않는다. 새로운 사실이 기존의 사실을 부정하게 되는 경우가 없다(단조성: Monotonicity)

→ 자칫 비교하기 복잡으로 명제들, 세팅에 맞춰서 내어놓...

단조증가: 참인 명제의 수가 점점 증가

비단조 추론

위의 가정이 적합하지 않은 문제에 대한 추론이 요구될 때

새로운 사실이 기존의 참인 사실과 모순될 수도 있다.

기존 지식 중 일부를 부정할 수도 있다.

→ 새로운 지식의 취득이 계속되어도 전체적으로 참인 사실의 수는 감소할 수도 있다.(단조 증가가 아니다)

비단조 추론이 필요한 상황: 불완전한 정보, 가변적 조건, 추론이 불가능할 때 그 상황에서 적절히 가정을 세울 수 있을 때.



비단조 추론 예

- 상황: 서울 → 대구 운전, 고속도로 정체, 대전 전에 국도진입, 초행이며 밤이고 인적 없음, 남동쪽으로 추정하면서 운전, 큰 강을 잇는 다리 지남 (현재 상황)

- 여행에 관련된 운전자의 지식 (복잡되지 않은 공간내 상인 사항)

사실1: 대전의 남쪽에는 전라도와 경상도가 있다

사실2: 전라도는 서쪽에 경상도는 동쪽에 있다.

... ..

사실25: 전라도 사람의 대부분은 전라도 사투리를 사용한다.

사실26: 경상도 사람의 대부분은 경상도 사투리를 사용한다.

사실27: 북쪽에서 전라도로 남향하면 만경강을 만나게 된다.

사실28: 북쪽에서 경상도로 남향하면 낙동강을 만나게 된다.

사실29: 낙동강을 지나면 대구까지는 자동차로 1시간 정도 걸린다.

... ..

사실50: 대구는 경상도에 있다.

현 상황에서의 운전자의 인식 사실

belief, 신뢰

기존의 논리적이 형평 명제만 위 등.
가끔은 직관을 활용.
남이 쉽게 믿고 있는데 아닐 수도...

신뢰1: 현재 남동쪽으로 여행 중이다.

신뢰2: 현재 경상도내에 있다.

신뢰3: 금방 지난 다리는 낙동강 위에 있다.

신뢰4: 목적지까지는 1시간 정도 걸린다.

→ 현재 위치에서의 방향과 참여라고 추정됨

다리를 건넌 뒤 라디오 청취(전라도 사투리 사용하는 것을 들음) 후 새롭게 획득한 지식

신뢰1: 현재 전라도내에 있다.

신뢰2: 현재 남서쪽으로 여행 중이다.

신뢰3: 금방 지난 다리는 만경강 위에 있다

기존의 belief가 깨져 걱정이 됨 것.

전라도 지역 방송 청취로 상황 인식 변화

새로운 지식의 획득이 신뢰 상황 모두를 변화시킴

새로운 지식의 획득이 신뢰 상황을 증가시키지 못함

(하나 감소함.)

부재 추론(Default Reasoning)

- 환경변수나 조건의 값이 부재 → 기본 값을 사용하여 추론
- 대부분 참일 것으로 추정되는 사항을 기초로 하여 결론을 이끌어 냄

a라는 전제조건이 증명가능하고, 이로부터 일관성 있게
b라고 가정할 수 있다면, b라고 결론 내릴 수 있다.

$a : M b$

예) b

비교할 수 있는
바다 때 함께 안 갔을지
이렇게 적지 않

$engineer(x) : M practical(x)$

$practical(x)$

engineer가 practical하게 행동하는 것 증명 불가

$scientist(x) : M theoretical(x)$

$theoretical(x)$

$engineer(x) : M practical(x)$

$scientist(x) : M theoretical(x)$

어떤 사람이 동시에 현실적이고 이론적일 수는 없다고 하면, 두 결과는 서로
상충하게 된다.

두 규칙 중 하나만 적용 → 최근 규칙이 우선이라고 가정 → $practical(x)$ 는

삭제됨 → 모순 해결

규칙의 적용순서에 상관없는 단조추론과는 비교됨

추정법(Abduction)

- 인과적 형태로 주어진 지식에 근거
- 결과로부터 원인을 추정하는 것이 일관성이 있으면 그 원인을 단정지음

($a \rightarrow b$)와 b 로부터 a 를 추정하는 것이 일관성이 있으면

a 라고 결론짓는다.(부재 추론의 한 방법)

$$a \rightarrow b$$

b가 참. 그러면 원인으로 개연성 해는 참이 아닐까?

$$\frac{b, M \ a}{a}$$

$$a \rightarrow b$$

$$\sim \text{electricity}(\text{car}) \rightarrow \sim \text{start}(\text{car})$$

$$\frac{\sim \text{start}(\text{car}), M \ \sim \text{electricity}(\text{car})}{\sim \text{electricity}(\text{car})}$$

*가설과 실제 결과가 일치할 때/일치 않을 때
→ 이럴 때 보면 일관성 지
다양한 가능성*

“자동차 축전지가 방전되면 시동이 걸리지 않는다”는 지식 이용

시동이 걸리지 않으면 축전지 방전이라고 결론 내릴 수 있다(단, 일관성이 유지되어야 함)

자동차의 다른 전기 장치들이 제대로 작동되면 축전지 방전에 대한 결론은 일관성을 잃음

앞 장보다도 많은 확률 수. 근거가 조금 더 있음

폐세계 가정(Closed World Assumption)

최대한 쓰면 안 됨. 무조건 가능함

- 특정의 닫힌 세계의 지식만으로 추론 → 닫힌 세계의 지식만으로 H라는 가설을 증명하는 것이 불가능하면 $\sim H$ 가 참이라고 가정
 - 예) 어떤 회사에 홍길동이 있는가?의 질의 → 회사의 데이터베이스 조회(이 데이터베이스는 전 사원에 대한 데이터를 가진다고 가정) → 조회결과가 없으면 답은 No.

실업사원이라 함은 그에게 이직하지 않았으므로
→ 그럼 이 직원도 퇴직
- 문제세계 내에서 증명될 수 없는 사실은 그 역이 존재한다고 결론내림
- $\sim H$ 를 폐세계에 추가하는 것이 타당한가?
 - 예1) 지구 밖의 우주에 생명체의 존재를 증명할 수 없다고 생명체가 없다고 결론 내릴 수 있는가?

폐세계에 가정하는 가능. 근지 외계인 존재 없다는 거 증명 못하면 일단은 인정 안함.
폐세계에 관한 것 다룰 경우 (있다는거 증명 못하면 없다 됨)
 - 예2) 어떤 사람 P가 학교 정문으로 들어가면 P는 학생 또는 교직원
 - P가 학생이라고 증명 불가
 - P가 교직원이라고 증명 불가

$\sim(\text{학생}(P) \vee \text{교직원}(P))$

$\text{학생}(P) \wedge \text{교직원}(P)$

→ 선택증 없으면 학생도 아니고 교직원도 아님.

일관성이 없는 지식

학생(P) \vee 교직원(P)

\sim 학생(P)

\sim 교직원(P)

사실유지 시스템(Truth Maintenance System; TMS)

비양조추론: 원래 참이었던 것이 새로운 것에 의해서 부정되는 것.

특정 시스템 내에 상호 모순되는 사실들을 정리하여 일관성을 유지시키는 시스템(∴비단조 시스템에 의해 추론된 결과는 이전의 참을 부정할 수 있음)

지원목록(Support List) 이용

지식들 사이의 지원(참으로 될 근거) 관계를 표현

지식1 [SL (참노드 리스트)(거짓노드 리스트)]

참노드는 지식1이 참이 되기 위해 IN되어야 할 노드 리스트

거짓노드는 지식1이 참이 되기 위해 OUT되어야 할 노드 리스트 (참참 참고)

날씨에 관련된 지식과 지원목록 예

노드번호 지식 지 원 목 록

1 날씨가 맑다

[SL (2)(3)]

→ 날씨가 맑으려면 2는 in, 3은 out되어야
= 2라는 명제에 맞고, 3라는 명제에 맞지 않음..

2 낮이다

[SL ()()]

← **전제(Premise)**

3 비가 온다

[SL ()(1)]

← 원근 참

4 따듯하다

[SL (1)(3)]

명제되는 게 맞는지..

5 습도가 높다

[SL (3)()]

← **Normal Deduction**

← 비가 온다만 신빙성 명제되는 것 X.

5번이 있어 3번이 들어오는 게 아니라
3번이 있어 5번이 들어옴 (둘은 참하다)

이 전제
부터에 대한
이정명제리스트

TMS 동작예

현재 TMS의 IN, OUT 상태

(참) IN 1, 2, 4

OUT 3, 5

→ 즉, 현재는 낮이며, 맑고, 따뜻한 상태가 정당함

얼마 후 추론 시스템이 “비가 온다”라고 결론을 내리면 TMS는

→ 노드 3을 IN에 넣는다.

→ 노드 3의 거짓리스트에 1이 있으므로 노드 1은 OUT된다.

→ 노드 3은 노드 4의 거짓리스트에 있으므로 노드 4는 OUT 된다.

→ 노드 3에 대해 normal deduction인 노드 5는 바로 IN된다.

IN 2, 3, 5

OUT 1, 4

→ 즉, 현재는 낮이며, 비가 오며 습도가 높은 상태가 정당함

^{support list}
노드 상호간의 관계를 사용하여 모순의 원인을 찾아 제거

→ 의존성에 의한 역추적(dependency-directed backtracking)

앞 강의 설명에 집중하지 X
3과 4가 모순되니 4가 나감다
참고

← 노드 1, 2, 3, 4, 5, 6, 7, 8, 9, 10, 11, 12, 13, 14, 15, 16, 17, 18, 19, 20, 21, 22, 23, 24, 25, 26, 27, 28, 29, 30, 31, 32, 33, 34, 35, 36, 37, 38, 39, 40, 41, 42, 43, 44, 45, 46, 47, 48, 49, 50, 51, 52, 53, 54, 55, 56, 57, 58, 59, 60, 61, 62, 63, 64, 65, 66, 67, 68, 69, 70, 71, 72, 73, 74, 75, 76, 77, 78, 79, 80, 81, 82, 83, 84, 85, 86, 87, 88, 89, 90, 91, 92, 93, 94, 95, 96, 97, 98, 99, 100, 101, 102, 103, 104, 105, 106, 107, 108, 109, 110, 111, 112, 113, 114, 115, 116, 117, 118, 119, 120, 121, 122, 123, 124, 125, 126, 127, 128, 129, 130, 131, 132, 133, 134, 135, 136, 137, 138, 139, 140, 141, 142, 143, 144, 145, 146, 147, 148, 149, 150, 151, 152, 153, 154, 155, 156, 157, 158, 159, 160, 161, 162, 163, 164, 165, 166, 167, 168, 169, 170, 171, 172, 173, 174, 175, 176, 177, 178, 179, 180, 181, 182, 183, 184, 185, 186, 187, 188, 189, 190, 191, 192, 193, 194, 195, 196, 197, 198, 199, 200, 201, 202, 203, 204, 205, 206, 207, 208, 209, 210, 211, 212, 213, 214, 215, 216, 217, 218, 219, 220, 221, 222, 223, 224, 225, 226, 227, 228, 229, 230, 231, 232, 233, 234, 235, 236, 237, 238, 239, 240, 241, 242, 243, 244, 245, 246, 247, 248, 249, 250, 251, 252, 253, 254, 255, 256, 257, 258, 259, 260, 261, 262, 263, 264, 265, 266, 267, 268, 269, 270, 271, 272, 273, 274, 275, 276, 277, 278, 279, 280, 281, 282, 283, 284, 285, 286, 287, 288, 289, 290, 291, 292, 293, 294, 295, 296, 297, 298, 299, 300, 301, 302, 303, 304, 305, 306, 307, 308, 309, 310, 311, 312, 313, 314, 315, 316, 317, 318, 319, 320, 321, 322, 323, 324, 325, 326, 327, 328, 329, 330, 331, 332, 333, 334, 335, 336, 337, 338, 339, 340, 341, 342, 343, 344, 345, 346, 347, 348, 349, 350, 351, 352, 353, 354, 355, 356, 357, 358, 359, 360, 361, 362, 363, 364, 365, 366, 367, 368, 369, 370, 371, 372, 373, 374, 375, 376, 377, 378, 379, 380, 381, 382, 383, 384, 385, 386, 387, 388, 389, 390, 391, 392, 393, 394, 395, 396, 397, 398, 399, 400, 401, 402, 403, 404, 405, 406, 407, 408, 409, 410, 411, 412, 413, 414, 415, 416, 417, 418, 419, 420, 421, 422, 423, 424, 425, 426, 427, 428, 429, 430, 431, 432, 433, 434, 435, 436, 437, 438, 439, 440, 441, 442, 443, 444, 445, 446, 447, 448, 449, 450, 451, 452, 453, 454, 455, 456, 457, 458, 459, 460, 461, 462, 463, 464, 465, 466, 467, 468, 469, 470, 471, 472, 473, 474, 475, 476, 477, 478, 479, 480, 481, 482, 483, 484, 485, 486, 487, 488, 489, 490, 491, 492, 493, 494, 495, 496, 497, 498, 499, 500, 501, 502, 503, 504, 505, 506, 507, 508, 509, 510, 511, 512, 513, 514, 515, 516, 517, 518, 519, 520, 521, 522, 523, 524, 525, 526, 527, 528, 529, 530, 531, 532, 533, 534, 535, 536, 537, 538, 539, 540, 541, 542, 543, 544, 545, 546, 547, 548, 549, 550, 551, 552, 553, 554, 555, 556, 557, 558, 559, 560, 561, 562, 563, 564, 565, 566, 567, 568, 569, 570, 571, 572, 573, 574, 575, 576, 577, 578, 579, 580, 581, 582, 583, 584, 585, 586, 587, 588, 589, 590, 591, 592, 593, 594, 595, 596, 597, 598, 599, 600, 601, 602, 603, 604, 605, 606, 607, 608, 609, 610, 611, 612, 613, 614, 615, 616, 617, 618, 619, 620, 621, 622, 623, 624, 625, 626, 627, 628, 629, 630, 631, 632, 633, 634, 635, 636, 637, 638, 639, 640, 641, 642, 643, 644, 645, 646, 647, 648, 649, 650, 651, 652, 653, 654, 655, 656, 657, 658, 659, 660, 661, 662, 663, 664, 665, 666, 667, 668, 669, 670, 671, 672, 673, 674, 675, 676, 677, 678, 679, 680, 681, 682, 683, 684, 685, 686, 687, 688, 689, 690, 691, 692, 693, 694, 695, 696, 697, 698, 699, 700, 701, 702, 703, 704, 705, 706, 707, 708, 709, 710, 711, 712, 713, 714, 715, 716, 717, 718, 719, 720, 721, 722, 723, 724, 725, 726, 727, 728, 729, 730, 731, 732, 733, 734, 735, 736, 737, 738, 739, 740, 741, 742, 743, 744, 745, 746, 747, 748, 749, 750, 751, 752, 753, 754, 755, 756, 757, 758, 759, 760, 761, 762, 763, 764, 765, 766, 767, 768, 769, 770, 771, 772, 773, 774, 775, 776, 777, 778, 779, 780, 781, 782, 783, 784, 785, 786, 787, 788, 789, 790, 791, 792, 793, 794, 795, 796, 797, 798, 799, 800, 801, 802, 803, 804, 805, 806, 807, 808, 809, 810, 811, 812, 813, 814, 815, 816, 817, 818, 819, 820, 821, 822, 823, 824, 825, 826, 827, 828, 829, 830, 831, 832, 833, 834, 835, 836, 837, 838, 839, 840, 841, 842, 843, 844, 845, 846, 847, 848, 849, 850, 851, 852, 853, 854, 855, 856, 857, 858, 859, 860, 861, 862, 863, 864, 865, 866, 867, 868, 869, 870, 871, 872, 873, 874, 875, 876, 877, 878, 879, 880, 881, 882, 883, 884, 885, 886, 887, 888, 889, 890, 891, 892, 893, 894, 895, 896, 897, 898, 899, 900, 901, 902, 903, 904, 905, 906, 907, 908, 909, 910, 911, 912, 913, 914, 915, 916, 917, 918, 919, 920, 921, 922, 923, 924, 925, 926, 927, 928, 929, 930, 931, 932, 933, 934, 935, 936, 937, 938, 939, 940, 941, 942, 943, 944, 945, 946, 947, 948, 949, 950, 951, 952, 953, 954, 955, 956, 957, 958, 959, 960, 961, 962, 963, 964, 965, 966, 967, 968, 969, 970, 971, 972, 973, 974, 975, 976, 977, 978, 979, 980, 981, 982, 983, 984, 985, 986, 987, 988, 989, 990, 991, 992, 993, 994, 995, 996, 997, 998, 999, 1000

확률에 기초한 추론

Bayes의 정리 이러한 답보다 먼저 지능 추론
형식화까지도 각광.

확신 인자(Certainty Factor) → 확률로 아서서만 확률과 배타적. 인간이 경험한 확률

Dempster-Shafer의 정리

확률기초

$P(E)$: 사건 E가 일어날 확률 (0~1사이의 실수)

제한된 수의 상호 배타적인 사건들의 확률의 합은 1

일반적인 다수 사건 공간에서의 사건들 사이의 관계

$$P(A \cup B) = P(A) + P(B) - P(A \cap B)$$

A와 B가 상호배타적이면 $P(A \cap B) = 0$ → 그리고 $P(A \cup B) = P(A) + P(B)$

$$P(A \cap B) = P(A)P(B) : \text{독립 사건일 때}$$

A와 B 사건은 서로에게 영향을 주지 않음

$$P(A|B) = P(A \cap B) / P(B) : \text{조건확률}$$

B사건에 영향 받아(발생 후에) A가 일어날 확률

A와 B가 상호배타적이면 $P(A \cap B) = 0$ 이므로 $P(A|B) = P(A \cap B) / P(B) = 0$

A와 B가 독립적이면 $P(A|B) = P(A)$, $P(B|A) = P(B)$ (\therefore 다른 사건에 영향 없음)

상호배타: 경기도민, 강원도민 수치상과도 다 안되잖아!

서로독립: 주사위 두 번 던지기

베이즈의 정리를 사용하는 문제에서는
상호배타인 경우와 서로독립인 경우는
다루지 않는 것으로 가정함




B사건이 전개 하에 A일 확률 = $\frac{P(A \cap B)}{P(B)}$

(예제 4.5)

Bayes의 정리

Bayes의 정리

$$P(B | A) = \frac{P(B \text{ ? } A)}{P(A)}$$



$$\cancel{P(B | A)P(A)} = P(B \text{ ? } A) = P(A \text{ ? } B) = P(A | B)P(B) \quad \text{이 둘이 같다면, 기종 양지}$$

$$P(B | A)P(A) = P(A | B)P(B)$$

$$\therefore P(B | A) = \frac{P(A | B)P(B)}{P(A)} \quad (\text{Bayes의 정리})$$

Bayes 정리의 확장(by Laplace)

S : **집합** 전체공간

$S = \{B_1, B_2, \dots, B_N\}$ 임의의 B_i, B_j 는 상호배타적

A : 임의의 사건 (정확히) 일 때

$$A = A \cap S$$

감자 매니아의 집합 \cap (서울 \cup 경기 \cup 강원 \cup ... \cup 제주)

$$= A \cap (B_1 \cup B_2 \cup \dots \cup B_N)$$

$$= (A \cap B_1) \cup (A \cap B_2) \cup \dots \cup (A \cap B_N)$$

$$P(A) = P(A | B_1)P(B_1) + P(A | B_2)P(B_2) + \dots + P(A | B_N)P(B_N)$$

확장된 Bayes 정리

S상의 임의의 부분 B_i 과 임의의 사건 A 에 대해서

$$P(B_i | A) = \frac{P(A | B_i)P(B_i)}{P(A | B_1)P(B_1) + P(A | B_2)P(B_2) + \dots + P(A | B_N)P(B_N)} = P(A)$$

증거
가정할 때
가설의 확률
배열
배열

Bayes 정리의 활용

E: 주어진 증거(evidence)

$H_k(k=1, 2, \dots, N)$: 고려할 수 있는 상호배타적인 N 개의 가설 중 하나에 대해서, 증거 E 가 주어졌을 때 가설 H_k 이 참일 확률은

$$P(H_k | E) = \frac{P(E | H_k)P(H_k)}{\sum_{i=1}^N P(E | H_i)P(H_i)}$$

$P(A)$ 가 극히 작기 때문에 복잡하게 고려하여 $P(A)$ 를 극소화하면 되기
배열과 배열의 유사하고 비슷

증거없이 특정한 가설 H_k 를
신뢰할 수 있는 확률

증거 E 에 대한
원인으로 H_k 를 고려할 수 있
는 정도
(원인 확률의 정리)

H_k 이 참일 때 E 라는 증거를
얻을 수 있는 확률

Bayes 정리의 활용 예

예) 겨울철 어떤 지역의 기침하는 사람이 감기일 확률

겨울철 이 지역 주민 15%가 감기에 걸림 $\rightarrow P(\text{감기}) = 0.15$

보통 감기 걸린 사람의 50%가 기침을 함 $\rightarrow P(\text{기침}|\text{감기}) = 0.5$

지역주민의 20%는 감기와 상관없이 기침을 함 $\rightarrow P(\text{기침}) = 0.2$

해)

$$P(\text{감기}) = 0.15$$

$$P(\text{기침}|\text{감기}) = 0.5$$

$$P(\text{기침}) = 0.2$$

$$\text{해답: } P(\text{감기}|\text{기침}) = P(\text{기침}|\text{감기})P(\text{감기})/P(\text{기침})$$

$$= 0.5 \times 0.15 / 0.2 = 0.375$$

여기 $P(\text{감기}|\text{기침})$ 보다 구하기 쉬움

기침한 것은 감기일 확률

더 많은 원인 있을 때 많은 원인 있을 확률에 반비례함
더 많은 원인일수록 더 많이 될수록 원인이 될 확률

4. 불확실성

Tom M. Mitchell → 의 제 인공지능에 나오는 문제

예) 암 검사에서 양성 반응이 나왔을 때, 실제 암일 확률

전체 집단 중 암환자의 비율

$$P(\text{cancer})=0.008, P(\sim\text{cancer})=0.992$$

$$P(+|\text{cancer})=0.98, P(-|\text{cancer})=0.02$$

암환자가 양성반응을 내는 경우 암환자가 음성반응을 내는 경우

$$P(-|\sim\text{cancer})=0.97, P(+|\sim\text{cancer})=0.03$$

암환자가 아닌 사람이 양성반응이 다른 경우 암환자가 아닌 사람이 음성반응이 다른 경우

해)

$$P(\text{cancer} | +) = \frac{P(+ | \text{cancer})P(\text{cancer})}{P(+)}$$

만남이 나왔을 때 암일 확률

→ 여가 너무 자꾸만 결국 0.2085라는 결과가 나온다고 해서 연필

$P(\text{cancer})$ 와 $P(\sim\text{cancer})$ 같은비타겟
 $P(\text{cancer}) + P(\sim\text{cancer}) = 1$

$$= \frac{P(+ | \text{cancer})P(\text{cancer})}{P(+ | \text{cancer})P(\text{cancer}) + P(+ | \sim\text{cancer})P(\sim\text{cancer})}$$

$$= \frac{0.98 \times 0.008}{0.98 \times 0.008 + 0.03 \times 0.992} = \frac{0.00784}{0.00784 + 0.02976}$$

$$= 0.2085$$

→ 50명 중 10명 꼴
 4/5 확률로 암 아님

4. 불확실성

예) 총선에서 여당 후보를 찍었다는 전제 하에 서울 사람일 확률

$$P(\text{서울} | \text{여당}) = \frac{P(\text{여당} | \text{서울}) P(\text{서울})}{P(\text{여당} | \text{서울}) P(\text{서울}) + P(\text{여당} | \text{경기}) P(\text{경기}) + \dots + P(\text{여당} | \text{제주}) P(\text{제주})}$$

but 지금 전국 득표율 안 익X
지역별 득표율은 나왔다고 가정

해)

$$P(\text{서울} | \text{여당}) = \frac{P(\text{여당} | \text{서울}) P(\text{서울})}{P(\text{여당} | \text{서울}) P(\text{서울}) + P(\text{여당} | \text{경기}) P(\text{경기}) + \dots + P(\text{여당} | \text{제주}) P(\text{제주})}$$

Bayes 정리의 활용의 어려움


n개의 증거, m개의 가설

$P(\text{여당} | \text{서울}), P(\text{여당} | \text{경기}), \dots$ $P(\text{여당})$ $P(\text{서울})$
(nm개의 조건확률)+(n개의 증거확률)+(m개의 가설확률)

제한된 영역, 간단한 문제

→ 최근: 복잡한 문제로 해결가능 (다양한 data 제공됨)

→ 인더스트리 많은 것에는
AI가게의 조건확률 구하기는 data 부족
→ 적은 인더스트리 만드는 수
베이지스 정리 활용도 수



확신인자 (Certainty factor : CF)

주어진 증거들로부터 어떤 결론이나 가설을 신뢰할 것인지 아닌지에 대한 정도를 정량화 하기 위한 방법

의료용 전문가 시스템인 MYCIN에서 채택

예) if : 환절기이고, 환자가 기침을 하고, 콧물을 흘리면

then : 환자가 감기에 걸렸다 (with CF=0.8)

신뢰척도(measure of belief:MB)와 불신척도(measure of disbelief:MD)

MB[c,e] - 주어진 증거 e에 의해 결론 c가 신뢰 받을 수 있는 척도

MD[c,e] - 주어진 증거 e에 의해 결론 c가 불신되는 척도

$CF[c,e] = MB[c,e] - MD[c,e]$ ($0 \leq MB, MD \leq 1$ 이므로 $-1 \leq CF \leq 1$ 인 실수)

누적확신인자(Cumulative certainty factor)

하나의 결론에 대해 다수의 증거나 규칙이 존재

$CF[c, e_c] = MB[c, e_c] - MD[c, e_a]$

e_c : 결론 c에 대해 현재까지의 모든 증거

e_f : 결론 c를 신뢰(for)하게 하는 모든 증거 (여러개의 증거)

e_a : 결론 c를 불신(against)하게 하는 모든 증거

4. 불확실성

누적 신뢰척도 MB[c,ef]와 누적 불신척도 MD[c,ea]를 계산

해답은 항상 똑같다!

$$MB[c,e1 \& e2] = 0 \text{ if } MD[c,e1 \& e2] = 1$$

해답이 더 이상 세기될 수 없을 정도로
이치나면 계산

$$\rightarrow = MB[c,e1] + MB[c,e2](1 - MD[c,e1]) \text{ otherwise}$$

해답에 증가한 신뢰
확신에 증가한 신뢰

$$MD[c,e1 \& e2] = 0 \text{ if } MB[c,e1 \& e2] = 1$$

해답이 더 이상 세기될 수 없을 정도로
이치나면 계산

$$= MD[c,e1] + MD[c,e2](1 - MD[c,e1]) \text{ otherwise}$$

이거 한 것...

확신인자 예)

결론 : 환자는 감기에 걸렸다

규칙1: 콧물이 흐르면 감기에 걸렸을 수 있다(CF=0.5)

규칙2: 기침으로 고생하면 감기에 걸렸을 수 있다(CF=0.3)

규칙3: 식욕이 왕성하면 감기에 걸렸을 수 있다(CF=-0.2)

규칙1 적용: MB=CF=0.5, MD=0

규칙2 적용: MB=0.5+0.3(1-0.5)=0.65, MD=0

규칙3 적용: MB=0.65, MD=0.2

누적 확신인자 CF=0.65-0.2=0.45

콧물 0.5, 기침 0.3, 식욕왕성 0.2인 사람이 감기에 걸렸다

0.5 + 0.3 * 0.5 = 0.65 (이것을 명제할 때 사용)

0.5 + 0.3 * 0.5 + 0.3 * 0.5 = 0.9 (이것을 명제할 때 사용)

확신에 양함 증가했다가
불신에 증가 (CF)가 계속되는...

MB[c, e1] = 0.5 (이치나면)

(1 - MD[c, e1]) = 0.5

→ 확신에 조금 증가하고 다음
확신에 양함 증가하도록...

하나의 증거가 다수의 결론에 도달
누적 신뢰척도 $MB[c,ef]$ 와 누적 불신척도 $MD[c,ea]$ 를 계산

$$MB[c_1 \square c_2, e] = \min (MB[c_1, e], MB[c_2, e])$$

$$MD[c_1 \square c_2, e] = \min (MD[c_1, e], MD[c_2, e])$$

$$MB[c_1 \square c_2, e] = \max (MB[c_1, e], MB[c_2, e])$$

$$MD[c_1 \square c_2, e] = \max (MD[c_1, e], MD[c_2, e])$$

생략

예)

증거 : 컴파일시 이상 없었는데 실행시키니 컴퓨터 화면이 이상

c1: 검사용 프로그램을 실행(CF=0.6)

c2: 문제는 소프트웨어(CF=0.9)

c3: 컴퓨터 바이러스에 감염(CF=0.3)

c4: 프로그램에 버그(CF=0.5)

$$MB[c_1 \square c_2 \square (c_3 \square c_4), e] = \min(MB[c_1, e], MB[c_2, e], MB[c_3 \square c_4, e])$$

$$= \min(MB[c_1, e], MB[c_2, e], \max(MB[c_3, e], MB[c_4, e]))$$

$$= \min(0.6, 0.9, \max(0.3, 0.5)) = 0.5$$

